

TỐI ƯU HOÁ NGỮ CẢNH (COOP) CHO MÔ HÌNH THỊ GIÁC-NGÔN NGỮ

Nguyễn Thanh Thảo

250104025

Tóm tắt

- Lớp: CS2205.CH201
- Link Github của nhóm:
<https://github.com/ngyxntthao/CS2205.CH201.git>
- Link YouTube video: <https://youtu.be/GGonwrCO23k>
- Họ và tên: Nguyễn Thanh Thảo
- MSHV: 250104025

Giới thiệu

Bối cảnh

- Các hệ thống nhận dạng hình ảnh truyền thống (như CNN) thường sử dụng nhãn văn bản rời rạc, làm hạn chế khả năng xử lý.
- Mô hình Vision-Language như CLIP đạt hiệu quả zero-shot nhờ prompt ngôn ngữ.

Vấn đề chính

- Prompt thủ công: Nhạy cảm với cách diễn đạt, yêu cầu có kiến thức chuyên môn và cực kỳ tốn thời gian để tinh chỉnh
- Cần phương pháp **prompt learning** có hệ thống hơn

Mục tiêu

- Mục tiêu 1: Tự động hóa thiết kế prompt bằng cách học các vector ngữ cảnh trực tiếp từ dữ liệu.
- Mục tiêu 2: Nâng cao hiệu quả học trong bối cảnh few-shot learning, ngay cả khi chỉ có ít mẫu huấn luyện cho mỗi lớp.
- Mục tiêu 3: Phân tích khả năng tổng quát hóa của prompt học được khi chuyển sang các miền dữ liệu khác.

Nội dung và Phương pháp

1. Tạo prompt từ context vectors $[v_1, \dots, v_n, \text{class name}]$
2. Text Encoder $\rightarrow$ thu được text embedding (frozen)
3. Image Encoder $\rightarrow$ thu được image embedding (frozen)
4. So khớp ảnh - văn bản bằng cosine similarity + softmax
5. Backprop chỉ update context vectors

Với hai biến thể Prompt

- Unified Context (UC): ngữ cảnh thống nhất
- Class-Specific Context (CSC): ngữ cảnh riêng cho từng lớp

Nội dung và Phương pháp




Fig. 2 Overview of Context Optimization (CoOp). The main idea is to model a prompt's context using a set of learnable vectors, which can be optimized through minimizing the classification loss. Two designs are proposed: one is unified context, which shares the same context vectors with all classes; and the other is class-specific context, which learns for each class a specific set of context vectors.

Kết quả dự kiến

Kịch bản 1: Few-Shot Learning

- Baseline: zero-shot CLIP, linear probe model [2][14]
- Dataset: ImageNet [3], Caltech101[4], Oxford-Pets [5], StanfordCars [6], Flowers102 [7], Food101 [8], FGVCAircraft [9], SUN397 [10], DTD [11], EuroSAT [12], UCF101 [13]

Kịch bản 2: Tổng quát hóa miền

- Baseline: zero-shot CLIP, linear probe model [2][14]
- Dataset: Train: ImageNet | Test: 4 biến thể (ImageNetV2, ImageNet-Sketch, ImageNet-A, ImageNet-R)

Kịch bản 3: Phân tích sâu hơn

- Baseline: Prompt engineering, Prompt ensembling [2]
- Dataset: 50% classes làm base (có train data), 50% classes làm novel (không có train data)
- Backbone: Sử dụng CLIP làm mô hình gốc với các kiến trúc như ResNet-50 và Vision Transformers (ViT)

Kết quả dự kiến

Kịch bản 1: Few-Shot Learning	CoOp vượt trội hơn hẳn so với prompt thủ công và linear probe, đặc biệt là trong các kịch bản ít dữ liệu (few-shot learning: 1, 2, 4, 8, 16 shots) Với Unified Context tốt hơn khi thiếu dữ liệu và Class-Specific Context tốt hơn khi có đủ.
Kịch bản 2: Tổng quát hóa miền	mô hình vẫn duy trì được độ chính xác rất cao.
Kịch bản 3: Phân tích sâu hơn	Ngữ cảnh dài hơn sẽ cho kết quả tốt hơn, và việc sử dụng ViT làm backbone mang lại độ chính xác cao nhất

Tài liệu tham khảo

- [1] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, Ziwei Liu. 2022. "Learning to Prompt for Vision-Language Models." *CVPR 2022*.
- [2] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever. 2021. "Learning Transferable Visual Models From Natural Language Supervision." *ICML 2021*.
- [3] J. Deng, W. Dong, R. Socher, L. -J. Li, Kai Li and Li Fei-Fei, "ImageNet: A large-scale hierarchical image database," *2009 IEEE Conference on Computer Vision and Pattern Recognition*, Miami, FL, USA, 2009, pp. 248-255, doi: 10.1109/CVPR.2009.5206848.
- [4] Li Fei-Fei, R. Fergus and P. Perona, "Learning Generative Visual Models from Few Training Examples: An Incremental Bayesian Approach Tested on 101 Object Categories," *2004 Conference on Computer Vision and Pattern Recognition Workshop*, Washington, DC, USA, 2004, pp. 178-178, doi: 10.1109/CVPR.2004.383.
- [5] O. M. Parkhi, A. Vedaldi, A. Zisserman and C. V. Jawahar, "Cats and dogs," *2012 IEEE Conference on Computer Vision and Pattern Recognition*, Providence, RI, USA, 2012, pp. 3498-3505, doi: 10.1109/CVPR.2012.6248092.
- [6] J. Krause, M. Stark, J. Deng and L. Fei-Fei, "3D Object Representations for Fine-Grained Categorization," *2013 IEEE International Conference on Computer Vision Workshops*, Sydney, NSW, Australia, 2013, pp. 554-561, doi: 10.1109/ICCVW.2013.77.
- [7] M. -E. Nilsback and A. Zisserman, "Automated Flower Classification over a Large Number of Classes," *2008 Sixth Indian Conference on Computer Vision, Graphics & Image Processing*, Bhubaneswar, India, 2008, pp. 722-729, doi: 10.1109/ICVGIP.2008.47.
- [8] Bossard, Lukas & Guillaumin, Matthieu & Van Gool, Luc. (2014). Food-101 – Mining Discriminative Components with Random Forests. 446-461. 10.1007/978-3-319-10599-4_29.
- [9] Maji, Subhansu & Rahtu, Esa & Kannala, Juho & Blaschko, Matthew & Vedaldi, Andrea. (2013). Fine-Grained Visual Classification of Aircraft. 10.48550/arXiv.1306.5151.
- [10] Xiao, Jianxiong & Hays, James & Ehinger, Krista & Oliva, Aude & Torralba, Antonio. (2010). SUN database: Large-scale scene recognition from abbey to zoo. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 3485-3492. 10.1109/CVPR.2010.5539970.
- [11] M. Cimpoi, S. Maji, I. Kokkinos, S. Mohamed and A. Vedaldi, "Describing Textures in the Wild," *2014 IEEE Conference on Computer Vision and Pattern Recognition*, Columbus, OH, USA, 2014, pp. 3606-3613, doi: 10.1109/CVPR.2014.461.

Tài liệu tham khảo

- [12] P. Helber, B. Bischke, A. Dengel and D. Borth, "EuroSAT: A Novel Dataset and Deep Learning Benchmark for Land Use and Land Cover Classification," in *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 12, no. 7, pp. 2217-2226, July 2019, doi: 10.1109/JSTARS.2019.2918242. Keywords:
- [13] Soomro, Khurram & Zamir, Amir & Shah, Mubarak. (2012). UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. CoRR.
- [14] Tian Y, Wang Y, Krishnan D, Tenenbaum JB, Isola P (2020) Rethinking few-shot image classification: a good embedding is all you need? In: ECCV