

## THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút):  
Cá nhân trình bày: <https://youtu.be/GGonwrCO23k>  
Video gốc: <https://www.youtube.com/watch?v=GjnVhuR2S6g>
- Link slides (dạng .pdf đặt trên Github của nhóm):  
<https://github.com/ngyxntthao/CS2205.CH201/blob/main/%5BSlide%5DLearningToPromptForVisionLanguageModels.pdf>
- Link github:  
Cá nhân: <https://github.com/ngyxntthao/CS2205.CH201.git>  
Source code gốc: <https://github.com/KaiyangZhou/CoOp>

- Họ và Tên: Nguyễn Thanh Thảo
- MSSV: 250104025
- Lớp: CS2205.CH201
- Tự đánh giá (điểm tổng kết môn): 9.5/10
- Số buổi vắng: 1
- Số câu hỏi QT cá nhân: 4

## **ĐỀ CƯƠNG NGHIÊN CỨU**

### **TÊN ĐỀ TÀI (IN HOA)**

TỐI ƯU HOÁ NGỮ CẢNH (COOP) CHO MÔ HÌNH THỊ GIÁC-NGÔN NGỮ

### **TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)**

LEARNING TO PROMPT FOR VISION-LANGUAGE MODELS

### **TÓM TẮT**

Các mô hình thị giác-ngôn ngữ như CLIP đã chứng minh khả năng mạnh mẽ trong nhận dạng hình ảnh bằng cách kết nối văn bản và hình ảnh. Thay vì huấn luyện riêng biệt cho từng tác vụ, CLIP sử dụng prompt (câu gợi ý bằng ngôn ngữ tự nhiên) như "a photo of a dog" để phân loại ảnh mà không cần dữ liệu huấn luyện mới (zero-shot learning).

Tuy nhiên, việc thiết kế prompt hiệu quả là cực kỳ khó: một thay đổi nhỏ trong cách diễn đạt có thể làm giảm độ chính xác đáng kể. Ví dụ, "a photo of a dog" có thể cho kết quả tốt hơn "a picture of a dog" đến 5-10%, nhưng không ai biết trước công thức tối ưu cho từng tác vụ. Quá trình thử-sai này (prompt engineering) tốn rất nhiều thời gian và công sức.

Nghiên cứu này tập trung vào Context Optimization (CoOp) - một phương pháp tự động học prompt tối ưu thay vì thiết kế thủ công. Ý tưởng cốt lõi: thay vì dùng các từ cố định như "a photo of", CoOp chuyển chúng thành các vector số có thể học được (giống như học trọng số trong neural network). Mô hình sẽ tự điều chỉnh các vector này dựa trên dữ liệu, trong khi giữ nguyên toàn bộ kiến thức đã học của CLIP.

CoOp có hai phiên bản: Unified Context (UC) - dùng chung một prompt cho tất cả lớp, và Class-Specific Context (CSC) - mỗi lớp có prompt riêng. Kết quả thực nghiệm trên 11 bộ dữ liệu cho thấy chỉ với 16 ảnh mẫu, CoOp cải thiện độ chính xác trung bình 15% so với prompt thủ công, trong một số trường hợp lên đến 45%. Quan trọng hơn, phương pháp này chỉ cần học 8,192 tham số (UC) hoặc vài triệu tham số (CSC) thay vì 150 triệu tham số của CLIP, giúp tiết kiệm tài nguyên và tránh overfitting.

### **GIỚI THIỆU (Tối đa 1 trang A4)**

Trước đây, để xây dựng hệ thống nhận dạng chó mèo, chúng ta cần thu thập hàng nghìn ảnh chó và mèo có gán nhãn, sau đó huấn luyện mô hình từ đầu hoặc fine-tune mô hình có sẵn.

Nếu muốn thêm loại mới (ví dụ: nhận dạng thỏ), phải thu thập thêm dữ liệu và huấn luyện lại toàn bộ mô hình - quá trình này tốn kém cả thời gian và tài nguyên.

Cách tiếp cận mới với CLIP (Contrastive Language-Image Pretraining, 2021) đã thay đổi paradigm này. CLIP được huấn luyện trên 400 triệu cặp ảnh-văn bản từ Internet, học cách "hiểu" mối quan hệ giữa ảnh và ngôn ngữ tự nhiên. Nhờ đó, CLIP có thể nhận dạng hình ảnh chỉ bằng cách mô tả bằng lời mà không cần dữ liệu huấn luyện mới:

Prompt: "a photo of a dog" → CLIP nhận dạng được ảnh chó

Prompt: "a photo of a cat" → CLIP nhận dạng được ảnh mèo

Đây chính là khả năng zero-shot learning - học mà không cần mẫu.

Tuy nhiên, hiệu suất của CLIP cực kỳ nhạy cảm với cách diễn đạt prompt. Việc lựa chọn prompt phù hợp cho từng tác vụ hiện vẫn phụ thuộc nhiều vào kinh nghiệm của người thiết kế và không có bảo đảm về tính tối ưu.

Để giải quyết vấn đề trên, CoOp đề xuất tự động học prompt từ dữ liệu thay vì thiết kế thủ công. Thay vì dùng các token ngôn ngữ cố định "a photo of a", CoOp chuyển chúng thành các vector số có thể học được:

Prompt thủ công: ["a", "photo", "of", "a", "dog"]

Prompt CoOp: [ $V_1$ ,  $V_2$ ,  $V_3$ ,  $V_4$ , "dog"]

được tối ưu trực tiếp từ dữ liệu huấn luyện trong khi giữ nguyên toàn bộ tham số của CLIP. Cách tiếp cận này cho phép mô hình thích nghi hiệu quả với tác vụ mới mà không phá vỡ kiến thức đã được học trước đó.

## **MỤC TIÊU (Viết trong vòng 3 mục tiêu)**

### Mục tiêu 1: Tự động hóa thiết kế prompt

Giảm sự phụ thuộc vào thiết kế prompt thủ công bằng cách học các vector ngữ cảnh trực tiếp từ dữ liệu.

### Mục tiêu 2: Nâng cao hiệu quả học trong bối cảnh few-shot learning

Khai thác kiến thức tiền huấn luyện của CLIP để đạt hiệu năng cao ngay cả khi chỉ có từ 1 đến 16 mẫu huấn luyện cho mỗi lớp.


### Mục tiêu 3: Phân tích khả năng tổng quát hóa của prompt học được

Đánh giá mức độ overfitting và khả năng áp dụng của prompt học được khi chuyển sang các miền dữ liệu khác.

## NỘI DUNG VÀ PHƯƠNG PHÁP

### Tổng quan


Nghiên cứu tập trung vào việc điều chỉnh mô hình thị giác-ngôn ngữ CLIP cho các tác vụ phân loại hình ảnh thông qua prompt learning. Phương pháp CoOp học các vector ngữ cảnh liên tục trong khi toàn bộ tham số của mô hình CLIP được giữ nguyên (frozen backbone).



### Kiến trúc CoOp

Toàn bộ mô hình CLIP được đóng băng, bao gồm image encoder và text encoder. Với kiến trúc ViT-B/16, CLIP có khoảng 150 triệu tham số và tất cả đều không được cập nhật trong quá trình huấn luyện.

Phần có thể học duy nhất là các vector ngữ cảnh của prompt. Với Unified Context, một bộ vector ngữ cảnh được dùng chung cho tất cả các lớp. Prompt tạo cho từng class, được biểu diễn:  $[v_1, v_2, \dots, v_M, C]$ , trong đó  $v_i \in \mathbb{R}^{512}$ : vector ngữ cảnh học được,  $c \in \mathbb{R}^{512}$ : embedding của tên lớp (cố định). Với Class-Specific Context, mỗi lớp có một bộ vector ngữ cảnh riêng. Prompt cho từng class, được biểu diễn  $[v_1^c, v_2^c, \dots, v_M^c, C]$



**Fig. 2 Overview of Context Optimization (CoOp).** The main idea is to model a prompt's context using a set of learnable vectors, which can be optimized through minimizing the classification loss. Two designs are proposed: one is unified context, which shares the same context vectors with all classes; and the other is class-specific context, which learns for each class a specific set of context vectors.

## Quy trình huấn luyện

Trong pha forward, prompt được xây dựng bằng cách ghép các vector ngữ cảnh học được với embedding cố định của tên lớp và đưa vào text encoder để thu được text embedding  $g(\text{prompt}) \in \mathbb{R}^{512}$  [frozen]. Song song đó, hình ảnh đầu vào được đưa qua image encoder  $f(\text{ảnh}) \in \mathbb{R}^{512}$  [frozen] để thu được image embedding. Độ tương đồng giữa hai biểu diễn được tính bằng cosine similarity và sử dụng để dự đoán nhãn (softmax)

Trong giai đoạn backward, hàm mất mát cross-entropy được sử dụng để cập nhật các vector ngữ cảnh thông qua gradient descent. Toàn bộ tham số của CLIP vẫn được giữ nguyên.

## KẾT QUẢ MONG ĐỢI

### Phương Pháp Baseline

Để đánh giá hiệu quả của CoOp, nghiên cứu so sánh với hai phương pháp baseline chính:

**Zero-shot CLIP:** Sử dụng prompt thủ công với template "a photo of a {class}" mà không cần dữ liệu huấn luyện. Phương pháp này đại diện cho khả năng tổng quát hóa thuần túy của mô hình tiền huấn luyện.

**Linear Probe CLIP:** Đóng băng toàn bộ CLIP và chỉ huấn luyện một lớp phân loại tuyến tính trên đầu ra của image encoder. Phương pháp này yêu cầu học từ  $512 \times K$  đến  $768 \times K$  tham số (với K là số lớp), nhiều hơn đáng kể so với CoOp.

### Thử nghiệm 1: Few-Shot Learning

Kịch bản few-shot learning được thiết kế nhằm đánh giá khả năng học của CoOp trong điều

kiện hạn chế về dữ liệu huấn luyện. Cụ thể, nghiên cứu tiến hành thực nghiệm trên 11 bộ dữ liệu phân loại ảnh đa dạng với số lượng mẫu huấn luyện biến thiên từ 1 đến 16 ảnh cho mỗi lớp ( $\text{shots} = \{1, 2, 4, 8, 16\}$ ). Các bộ dữ liệu được lựa chọn bao gồm: ImageNet (1,000 lớp), Caltech101 (100 lớp), Oxford Pets (37 lớp), Stanford Cars (196 lớp), Oxford Flowers (102 lớp), Food101 (101 lớp), FGVC Aircraft (100 lớp), DTD (47 lớp), SUN397 (397 lớp), EuroSAT (10 lớp), UCF101 (101 lớp).

Kết quả mong đợi:

- Cả hai biến thể UC và CSC đều vượt qua zero-shot CLIP một cách đáng kể ngay
- Trong môi trường cực kỳ hạn chế dữ liệu (1-4 shots), UC thể hiện ưu thế rõ rệt với độ chính xác cao hơn CSC, do UC sử dụng chung một bộ context vectors cho tất cả các lớp, do đó có khả năng tổng quát hóa tốt hơn khi thiếu dữ liệu. Tuy nhiên, khi số lượng shots tăng lên 8 và 16, CSC bắt đầu bộc lộ tiềm năng với độ chính xác vượt UC

### Thử nghiệm 2: Cross-Domain Generalization

Kịch bản domain generalization được thiết kế để đánh giá khả năng của CoOp khi phải hoạt động trên các domain out-of-distribution (OOD). Cụ thể, nghiên cứu sử dụng ImageNet làm source domain để huấn luyện với đầy đủ dữ liệu (1,000 lớp, 1.28 triệu ảnh training), sau đó đánh giá trên 4 target domains (ImageNetV2, ImageNet-Sketch, ImageNet-A, ImageNet-R). Mô hình được huấn luyện trên tập train ImageNet và đánh giá trên các tập dữ liệu test khác miền như (ImageNetV2, ImageNet-Sketch, ImageNet-A, ImageNet-R). Mục tiêu là phân tích khả năng tổng quát hóa của prompt học được khi phân phối dữ liệu thay đổi.

Kết quả định lượng mong đợi:

- Zero-shot CLIP duy trì tổng quát hóa tốt nhất: do quá trình tiền huấn luyện trên 400 triệu cặp ảnh-text đa dạng từ internet, giúp mô hình học được các biểu diễn đặc trưng có tính tổng quát cao.
- Linear Probe bị suy giảm nghiêm trọng: bộ phân loại tuyến tính học các đặc tính riêng biệt để phân phối ImageNet nhưng không nắm bắt được các đặc điểm bất biến trên domains.
- CoOp (UC) cân bằng tốt giữa accuracy và generalization: việc sử dụng chung một bộ context vectors cho tất cả các lớp, UC buộc mô hình phải học các prompt patterns có tính tổng quát cao thay vì overfit vào các đặc trưng riêng biệt của từng lớp
- CoOp (CSC) gặp khó khăn với domain shift: mặc dù cho phép mô hình học các

prompt tối ưu cho từng lớp trên source domain, lại làm tăng nguy cơ overfitting và giảm khả năng tổng quát hóa.

### Thử nghiệm 3: Phân Tích Chuyên Sâu (Further Analysis)

Prompt được học trên các lớp cũ, khi gặp lớp mới (unseen classes). Mô hình có còn hoạt động tốt không, hay chỉ “nhớ” các lớp cũ?

Để trả lời câu hỏi này, nghiên cứu thiết kế kịch bản base-to-novel generalization như sau:

1. Chia ngẫu nhiên tập K lớp của mỗi dataset thành hai tập con bằng nhau: base classes (có dữ liệu huấn luyện) và novel classes (không có dữ liệu huấn luyện)
2. Huấn luyện CoOp chỉ trên base classes với 16 shots per class
3. Đánh giá hiệu suất trên cả base và novel classes
4. Sử dụng harmonic mean (H) để đo lường sự cân bằng giữa hai tập:

Kết quả kỳ vọng:

- Overfitting vào Base Classes: Cả CoOp (UC) và CoOp (CSC) đều cho thấy hiện tượng rõ ràng: độ chính xác tăng mạnh trên base classes nhưng lại giảm trên novel classes. Điều này chứng tỏ rằng các context vectors được học có xu hướng overfitting vào các đặc trưng đặc thù của base classes mà nó được huấn luyện, dẫn đến sự suy giảm khả năng tổng quát hóa sang các lớp mới.
- Ảnh Hưởng của số lượng context tokens: Accuracy tăng đều đặn khi M tăng, phản ánh việc mô hình có nhiều capacity hơn để học các patterns phức tạp. Khi M tăng lên 32 và 64, accuracy bắt đầu giảm xuống, với quá nhiều parameters, mô hình học nhớ (memorize) training data thay vì học các patterns tổng quát hóa.

### **TÀI LIỆU THAM KHẢO (Định dạng DBLP)**

- [1] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, Ziwei Liu. 2022. “Learning to Prompt for Vision-Language Models.” *CVPR 2022*.
- [2] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever. 2021. “Learning Transferable Visual Models From Natural Language Supervision.” *ICML 2021*.
- [3] J. Deng, W. Dong, R. Socher, L. -J. Li, Kai Li and Li Fei-Fei, "ImageNet: A large-scale hierarchical image database," *2009 IEEE Conference on Computer Vision and*

- Pattern Recognition*, Miami, FL, USA, 2009, pp. 248-255, doi: 10.1109/CVPR.2009.5206848.
- [4] Li Fei-Fei, R. Fergus and P. Perona, "Learning Generative Visual Models from Few Training Examples: An Incremental Bayesian Approach Tested on 101 Object Categories," *2004 Conference on Computer Vision and Pattern Recognition Workshop*, Washington, DC, USA, 2004, pp. 178-178, doi: 10.1109/CVPR.2004.383.
- [5] O. M. Parkhi, A. Vedaldi, A. Zisserman and C. V. Jawahar, "Cats and dogs," *2012 IEEE Conference on Computer Vision and Pattern Recognition*, Providence, RI, USA, 2012, pp. 3498-3505, doi: 10.1109/CVPR.2012.6248092.
- [6] J. Krause, M. Stark, J. Deng and L. Fei-Fei, "3D Object Representations for Fine-Grained Categorization," *2013 IEEE International Conference on Computer Vision Workshops*, Sydney, NSW, Australia, 2013, pp. 554-561, doi: 10.1109/ICCVW.2013.77.
- [7] M. -E. Nilsback and A. Zisserman, "Automated Flower Classification over a Large Number of Classes," *2008 Sixth Indian Conference on Computer Vision, Graphics & Image Processing*, Bhubaneswar, India, 2008, pp. 722-729, doi: 10.1109/ICVGIP.2008.47.
- [8] Bossard, Lukas & Guillaumin, Matthieu & Van Gool, Luc. (2014). Food-101 – Mining Discriminative Components with Random Forests. 446-461. 10.1007/978-3-319-10599-4\_29.
- [9] Maji, Subhransu & Rahtu, Esa & Kannala, Juho & Blaschko, Matthew & Vedaldi, Andrea. (2013). Fine-Grained Visual Classification of Aircraft. 10.48550/arXiv.1306.5151.
- [10] Xiao, Jianxiong & Hays, James & Ehinger, Krista & Oliva, Aude & Torralba, Antonio. (2010). SUN database: Large-scale scene recognition from abbey to zoo. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 3485-3492. 10.1109/CVPR.2010.5539970.
- [11] M. Cimpoi, S. Maji, I. Kokkinos, S. Mohamed and A. Vedaldi, "Describing Textures in the Wild," *2014 IEEE Conference on Computer Vision and Pattern Recognition*, Columbus, OH, USA, 2014, pp. 3606-3613, doi: 10.1109/CVPR.2014.461.

- [12] P. Helber, B. Bischke, A. Dengel and D. Borth, "EuroSAT: A Novel Dataset and Deep Learning Benchmark for Land Use and Land Cover Classification," in *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 12, no. 7, pp. 2217-2226, July 2019, doi: 10.1109/JSTARS.2019.2918242. Keywords:
- [13] Soomro, Khurram & Zamir, Amir & Shah, Mubarak. (2012). UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. CoRR.
- [14] Tian Y, Wang Y, Krishnan D, Tenenbaum JB, Isola P (2020) Rethinking few-shot image classification: a good embedding is all you need? In: ECCV